



APACHE SPARK SQL

A complex database schema diagram in the background, featuring various tables and their relationships. The tables include:

- ANA_OBJECT**: Attributes include OBJ_OID (PK), OBJ_CREATION_DATETIME, and OBJ_CREATOR_FK.
- ANA_RELATIONSHIP**: Attributes include REL_OID (FK), REL_RELATIONSHIP, REL_CHILD_FK (FK), REL_PARENT_FK (FK), and REL_SEQUENCE.
- ANA_STAGE**: Attributes include STG_OID (FK), STG_SPECIES_FK (FK), STG_NAME, STG_SEQUENCE, STG_DESCRIPTION, STG_SHORT_EXTRA_TEXT, and STG_PUBLIC_ID.
- ANA_ATTRIBUTION**: Attributes include ATR_OID (FK), ATR_OBJECT_FK (FK), ATR_SOURCE_FK (FK), ATR_EVIDENCE_FK (FK), and ATR_COMMENTS.
- REF_SPECIES**: Attributes include RSP_NAME, RSP_LATIN_NAME, RSP_TIMED_NODE_ID_PREFIX, and RSP_NODE_ID_PREFIX.
- SOURCE**: Attributes include SRC_OID (FK), SRC_NAME, SRC_AUTHORS, and SRC_FON.

Relationships are indicated by lines with crow's foot notation symbols (diamonds for one-to-one, crow's foot for one-to-many, and crow's foot with a vertical bar for many-to-many).

Profesores:
Miguel Angel Sánchez Hernández
Omar Mendoza González

Alumna:

Belem Anahi Mendieta Hernández

Contenido

- ¿Qué es Apache Spark?
- Fuentes de datos compatibles
- Componentes esenciales de Spark SQL
- ¿Qué es Spark SQL?
- Arquitectura de Spark SQL
- Ventajas de Spark SQL

¿Qué es Apache Spark?

Es un motor de procesamiento distribuido en memoria, diseñado para ser más rápido y flexible, capaz de procesar grandes volúmenes de datos de manera eficiente.

Características clave:

- Más rápido que MapReduce.
- Procesamiento en memoria.
- Compatible con YARN y HDFS.

Fuentes de datos compatibles

Spark soporta múltiples formatos:



Archivo de texto plano que almacena datos tabulares separados por comas

```
id,nombre,edad,pais  
1,Ana,22,MX  
2,Luis,24,USA
```



Formato de texto ligero basado en estructuras de clave-valor

```
{  
  "id": 1,  
  "nombre": "Ana",  
  "edad": 22,  
  "pais": "MX"  
}
```



Formato binario de almacenamiento de datos que incluye el esquema junto con los datos

```
{  
  "namespace": "example.avro",  
  "type": "record",  
  "name": "User",  
  "fields": [  
    { "name": "id", "type": "int" },  
    { "name": "nombre", "type": "string" },  
    { "name": "edad", "type": "int" },  
    { "name": "pais", "type": "string" }  
  ]  
}
```




JDBC/SQL

- **JDBC**: API para conectarse a bases de datos desde aplicaciones.
- **SQL**: Lenguaje para consultar, insertar y modificar datos en bases de datos.

```
SELECT
  d.breed,
  d.height,
  d.weight,
  s.amount,
  s.sale_date
FROM    dogs  AS d
LEFT JOIN sales AS s ON d.ID = s.dog_ID
        AND blah = blah
WHERE d.weight > 0.5
      AND s.sale_date >= '2022-01-01'
```



ORC

Formato de almacenamiento columnar optimizado para consultas



Parquet

Formato de almacenamiento columnar optimizado para análisis de grandes volúmenes de datos

```
Column: id      → [1, 2]
Column: nombre → ["Ana", "Luis"]
Column: pais    → ["MX", "USA"]
```



Hive tables


Tablas gestionadas dentro de un sistema de almacenamiento distribuido que consultan grandes volúmenes de datos.

Componentes esenciales de Spark SQL



SparkSession

Punto de entrada a Spark SQL.



DataFrames

Tablas distribuidas con columnas y tipos.



DataSets

Versión tipada de DataFrames



RDD

Colección de objetos dividida en particiones y procesada en paralelo.



SQL API

Ejecuta consultas directamente

¿Qué es Spark SQL?


Es el módulo de Apache Spark para trabajar con datos estructurados utilizando:

- SQL estándar
- DataFrames
- Datasets.

Permite ejecutar consultas distribuidas de forma optimizada y muy eficiente.




Arquitectura de Spark SQL



Catalyst Optimizer

- Optimiza automáticamente las consultas.
- Genera planes lógicos y físicos eficientes.



Tungsten Engine

- Motor físico optimizado.
- Manejo de memoria de bajo nivel para máxima velocidad.

Ventajas de Spark SQL

- Muy rápido (optimización automática).
- Fácil para usuarios de SQL.
- Escala desde una computadora hasta un clúster de cientos de nodos.
- Se integra con MLlib, Streaming y GraphX.

